
Interpretabilidade e Consistência em Modelos de Análise Preditiva: Uma Avaliação em Cenários com Dados Imperfeitos

Discente: Thállys Lemos Correa

Orientador: Sandro da Silva Camargo

Problema

- Lacuna: Desde os últimos cinco anos, as pesquisas que utilizam modelos atuais focam em acurácia, mas são "caixas-pretas".
- Desafio: Como esses modelos se comportam com dados ruidosos ou incompletos?
- Pergunta de Pesquisa: Como melhorar a interpretabilidade e a consistência desses modelos para aplicação em contextos reais?

Objetivos

- Revisar literatura sobre técnicas de interpretabilidade e modelos intrinsecamente explicáveis e consistência frente a dados ruidosos ou incompletos;
- Selecionar e preparar conjunto de dados com características imperfeitas;
- Implementar e comparar modelos preditivos por critérios de acurácia e explicabilidade;
- Avaliar essas técnicas, seus contextos e sua aplicação em cenários reais.

Revisão de Literatura

Modelos preditivos

Interpretabilidade

Dados imperfeitos



Implementação e Avaliação

Regressão Logística

KNN

Decision Tree

Random Forest

XGBoost

SHAP e LIME


F1-score

AUC-ROC

KMeans

Hierarchical Clustering


DBSCAN



Seleção e Preparação dos Dados

Datasets públicos

Inserção de ruído gaussiano em
três níveis: baixo, médio e alto



Estruturação do Framework

Diretrizes práticas

Fluxo de decisão para seleção e
interpretação de modelos

Base de dados

- Nome da base: Iris
- Data de publicação original: 1936
- Repositório: UCI Machine Learning Repository
- Área de aplicação: Biologia
- Tipo de dados: Tabular
- Número de instâncias: 150
- Número de atributos: 4 atributos numéricos
- Classe alvo: Espécie da flor
- Valores ausentes: Não possui valores ausentes.
- Saídas: *Iris setosa*; *Iris versicolor* ou *Iris virginica*;



Variável	Comprimento da Sépala (sepal length)	Largura da Sépala (sepal width)	Comprimento da Pétala (petal length)	Largura da Pétala (petal width)	Espécie da Flor (class)
Tipo	Numérica	Numérica	Numérica	Numérica	Categórica

Modificações no dataset

- Aplicação de mixup para um aumentar a base de dados para um total de 1000 instâncias:
 - Iris-setosa: 50 → 351;
 - Iris-versicolor: 50 → 321;
 - Iris-virginica: 50 → 328.
- Alpha = 0,2
- Random_state = 42

Principais funções utilizadas

- preparar_dados(df, coluna_alvo);
- separar_dados(df, coluna_alvo);
- definir_modelos();
- avaliar_modelos(df, coluna_alvo, k=5);
- executar_pipeline(df, coluna_alvo);
- funções plots de todos os algoritmos utilizados;


Nome da base	Proporção de Ruído
Iris_base	0,0%
Iris_baixo	10,0%
Iris_médio	20,0%
Iris_alto	30,0%

Algoritmos e métricas utilizadas

1. **Regressão Logística** - Estima a probabilidade de uma classe (ex.: sim/não).
2. **KNN** - Classifica um exemplo com base nas classes dos seus k vizinhos mais próximos.
3. **Decision Tree** - Toma decisões por meio de divisões sucessivas em forma de árvore.
4. **Random Forest** - Conjunto de várias árvores de decisão cuja votação reduz erros e melhora a consistência.
5. **XGBoost** - Algoritmo de gradient boosting que combina árvores sequencialmente para maximizar a precisão.
6. **KMeans** - Algoritmo de agrupamento que divide os dados em k grupos com centroides.
7. **Hierarchical Clustering** - Agrupa uma hierarquia representada por um dendrograma.
8. **DBSCAN** - Agrupa por densidade, identificando clusters arbitrários e outliers
9. **F1-Score** - Média harmônica entre precisão e revocação, equilibrando ambas.
10. **AUC-ROC** - Mede a capacidade de distinguir entre classes em diferentes limiares.
11. **Acurácia** - Proporção de previsões corretas em relação ao total de exemplos
12. **SHAP** - Método que quantifica a contribuição de cada variável para uma previsão.
13. **LIME** - Explica previsões individuais aproximando localmente o comportamento.


Gráfico de barras comparativo de sepal length

Sepal_leght Sepal_lenght_baixo Sepal_lenght_médio Sepal_lenght_alto




Matrize de correlação em heatmap


Iris_base








Iris_baixo




Iris_médio



Iris_alto




Impacto dos Níveis de Ruído nas Correlações (Treinamento)




Impacto dos Níveis de Ruído nas Correlações (Treino)


● Base ● Baixo ● Médio ● Alto




Iris_base




Iris_baixo




Iris_médio




Iris_alto




Iris_base - Treino: 93,62% | Teste: 93,5%




Iris_baixo - Treino: 92,88% | Teste: 91%




Iris_médio - Treino: 89,38% | Teste: 87,5%




Iris_alto - Treino: 87,25% | Teste: 83,5%




Iris_base - Treino: 96,88% | Teste: 95%




Iris_baixo - Treino: 96,25% | Teste: 92,5%




Iris_médio - Treino: 95,75% | Teste: 88%




Iris_alto - Treino: 94,88% | Teste: 89%




Iris_base - Treino: 93,38% | Teste: 89,5%




Iris_baixo - Treino: 92,25% | Teste: 87,5%




Iris_médio - Treino: 88,62% | Teste: 84%




Iris_alto - Treino: 87,5% | Teste: 82%




Iris_base - Treino: 95,5% | Teste: 92,5%




Iris_baixo - Treino: 95,12% | Teste: 92%




Iris_médio - Treino: 93,88% | Teste: 90%




Iris_alto - Treino: 91,62% | Teste: 87,5%




Iris_base - Treino: 99,38% | Teste: 94%




Iris_baixo - Treino: 99,12% | Teste: 94%




Iris_médio - Treino: 98,62% | Teste: 90,5%




Iris_alto - Treino: 99,62% | Teste: 91%




Curvas ROC




Curvas ROC




Curvas ROC



Curvas ROC



Comparativo de Métricas




Legenda:


- **F1-Score:** tons de ciano - azul escuro
- **AUC-ROC:** tons de rosa - roxo
- **Acurácia:** tons de amarelo - laranja
- Os modelos estão distribuídos em cores, quanto mais escura a cor, maior o ruído.

Iris_base


Elbow Curve - K-Means




Dendrograma - Hierarchical Clustering (Ward)




K-Means (k=3, PCA 2D)



Hierarchical Clustering (k=3, PCA 2D)




DBSCAN (eps=0.5, min_samples=5)
4 clusters | 21 pontos de ruído




Iris_baixo


Elbow Curve - K-Means




Dendrograma - Hierarchical Clustering (Ward)




K-Means (k=3, PCA 2D)



Hierarchical Clustering (k=3, PCA 2D)




DBSCAN (eps=0.5, min_samples=5)
3 clusters | 18 pontos de ruído




Iris_médio


Elbow Curve - K-Means




Dendrograma - Hierarchical Clustering (Ward)




K-Means (k=3, PCA 2D)



Hierarchical Clustering (k=3, PCA 2D)




DBSCAN (eps=0.5, min_samples=5)
6 clusters | 19 pontos de ruído




Iris_alto


Elbow Curve - K-Means




Dendrograma - Hierarchical Clustering (Ward)




K-Means (k=3, PCA 2D)




Hierarchical Clustering (k=3, PCA 2D)




DBSCAN (eps=0.5, min_samples=5)
14 clusters | 35 pontos de ruído




Iris_base




Iris_baixo



Iris_médio



Iris_alto



Feature	Value
sepal width	1,4
petal width	3,5
sepal length	0,2
petal length	5,1

Feature	Value
sepal width	1,7
petal width	3,49
sepal length	0,19
petal length	5,13

Feature	Value
sepal width	3,49
petal width	0,18
sepal length	5,15
petal length	2,01





Feature	Value
sepal width	3,48
petal width	0,17
sepal length	5,18
petal length	2,31

sepal width > 3,35
petal width <= 0,38
sepal length <= 5,20
petal length <= 1,67

sepal width > 3,34
petal width <=0,39
sepal length <= 5,19
petal length <= 1,74

sepal width > 3,33
petal width <=0,47
sepal length <= 5,21
1,93 < petal length

sepal width > 3,36
petal width <=0,55
sepal length <= 5,27
2,09 < petal length



Resultados dos Modelos Supervisionados frente ao Ruído

- Modelos lineares tentam se inclinar para alcançar outliers ruidosos, distorcendo a importância real das variáveis;
- Modelos baseados em distância são extremamente sensíveis ao ruído pois o ruído gaussiano espalha os pontos no espaço dimensional, fazendo com que as fronteiras se tornem irregulares e fragmentadas;
- Modelos baseados em regras tem uma tendência ao overfitting na presença de ruído se não forem podados por conta das ramificações excessivamente profundas para explicar os outliers;
- Boosting gradiente é o mais resiliente dos ruídos devido ao mecanismo de aprendizado sequencializado e enfoque em regularização de erros reais;
- O ruído gerado compromete o limiar de decisão por conta da queda da acurácia e do F1-Score, mas como o AUC-ROC manteve-se majoritariamente estacionário, não houve modificações significativas que afetassem a separabilidade entre as classes.

Resultados dos Algoritmos de Agrupamento frente ao Ruído

- K-Means: Manteve 3 clusters em todos os cenários, mas com centroides progressivamente deslocados pelo ruído;
- Hierarchical Clustering: Preservou a separação macro, mas o dendrograma foi progressivamente fragmentado, o que mostra que um efeito cascata nas fusões iniciais compromete a estrutura interna;
- DBSCAN: Classifica o ruído nativamente. Pontos classificados como outliers aumentaram, fragmentando a densidade em múltiplos micro-clusters.

DBScan como indicador de ruído:

- Base: 4 clusters — 21 outliers;
 - Os agrupamentos Versicolor e Virginica foram divididos devido a pequenos vazios de densidade, que o algoritmo interpretou como fronteiras.
- Baixo: 3 clusters — 18 outliers;
 - O ruído espalhou as amostras, aproximando-as e preenchendo os vazios.
- Médio: 6 clusters — 19 outliers;
- Alto: 14 clusters — 35 outliers.

Resultados sobre a Consistência das explicações

O modelo continua tomando decisões pelos mesmos motivos?

- Isso depende da perspectiva analítica considerada.

SHAP - Globalmente

Hierarquia de importância estável:

1. Comprimento da pétala
2. Largura da pétala
3. Comprimento da sépala
4. Largura da sépala

LIME - Localmente

Limiar de decisão deslocado

- Base $\rightarrow$ 5,1
- Baixo $\rightarrow$ 5,13
- Médio $\rightarrow$ 2,01
- Alto $\rightarrow$ 2,31

SHAP indica estabilidade na lógica global do modelo, mesmo na presença de ruído. LIME evidencia maior sensibilidade das decisões locais às perturbações. Assim, os métodos são complementares pois o SHAP explica o comportamento global, enquanto o LIME identifica regiões de maior instabilidade nas decisões.

Conclusão

- Os modelos de classificação demonstraram que, apesar da queda na acurácia sob ruído, a capacidade de ordenação/discriminação das classes (AUC-ROC) tendeu a se manter estável;
- Os algoritmos de agrupamento evidenciaram como as perturbações afetam a topologia dos dados, reforçando a viabilidade de usá-los para avaliar a sensibilidade de rótulos;
- O melhor algoritmo não é o que performa mais na base limpa, mas o que apresenta a menor taxa de degradação e a maior consistência explicativa (SHAP/LIME) frente a imperfeições;
- Consolidação de uma análise multidimensional que integra simultaneamente Desempenho (métricas), Explicação (interpretabilidade) e Estrutura (dados);
- Trabalhos Futuros: Replicação do pipeline em conjuntos de dados de múltiplos domínios, visando consolidar a metodologia como um framework generalizável.

Dúvidas?
